

Predicción del Rendimiento Académico mediante un Perceptrón Multicapa (MLP)

Calero López G.¹, Vásconez Pozo D.¹ y Viteri Ayala K.¹

¹Universidad Internacional del Ecuador

Docente: Rodriguez Chivata J.

Código fuente [Proyecto en Google Colab](#)

1. Resumen del Problema

El presente proyecto implementa un Perceptrón Multicapa (MLP) para predecir el rendimiento académico de estudiantes a partir de variables relacionadas con sus hábitos de estudio y antecedentes académicos, utilizando el Student Performance Dataset de Kaggle.

La variable objetivo es **Performance Index**, una medida numérica continua del desempeño estudiantil. Al ser una variable continua, el problema se aborda como una tarea de regresión supervisada. La arquitectura seleccionada es un MLP implementado en Keras/TensorFlow, adecuado para datos tabulares con relaciones lineales y no lineales.

Pregunta principal: ¿Qué factores académicos y hábitos de estudio permiten predecir el rendimiento académico de un estudiante?

Preguntas secundarias: ¿Son las calificaciones previas el principal predictor? ¿Estudiar más horas mejora el desempeño? ¿Influyen las horas de sueño y las actividades extracurriculares?

2. Preparación del Dataset

2.1. Descripción del Dataset

El Student Performance Dataset fue obtenido de Kaggle y contiene información de 10.000 estudiantes. Cada registro incluye variables relacionadas con hábitos de estudio, antecedentes académicos y actividades complementarias. La variable objetivo, **Performance Index**, es una medida numérica continua del desempeño académico que toma valores entre 10 y 100 puntos. El conjunto no presenta desbalance, lo que lo hace adecuado para aplicar técnicas de regresión supervisada.

Cuadro 1. Resumen general del dataset

Característica	Descripción
Número de muestras	10.000 registros
Variables predictoras	5 (4 num., 1 categ.)
Variable objetivo	Performance Index
Tipo de tarea	Regresión supervisada
Tipo de variables	Númericas + categórica binaria
Rango del target	10 – 100 puntos
Valores faltantes	Ninguno

Cuadro 2. Variables del modelo

Variable	Tipo	Rol
Hours Studied	Númerica	Predictora
Previous Scores	Númerica	Predictora
Extracurricular Act.	Categ. (binaria)	Predictora
Sleep Hours	Númerica	Predictora
Sample Q. Papers	Númerica	Predictora
Performance Index	Númerica	Objetivo

Las variables predictoras recogen distintas dimensiones del proceso de aprendizaje: **Hours Studied** indica el número de horas diarias dedicadas al estudio; **Previous Scores** refleja el rendimiento académico histórico del estudiante; **Extracurricular Activities** señala si el estudiante participa en actividades fuera del aula (Yes/No, codificada como 1/0); **Sleep Hours** registra las horas de sueño por noche; y **Sample Question Papers Practiced** cuenta el número de exámenes de práctica resueltos. La variable objetivo **Performance Index** representa el nivel de desempeño académico alcanzado, expresado en una escala continua de 10 a 100 puntos.

La distribución del **Performance Index** es aproximadamente uniforme, con media y mediana muy similares (Figura 1). La matriz de correlación (Figura 2) con-

firma que **Previous Scores** es la variable más asociada al rendimiento ($r = 0.915$), seguida de **Hours Studied** ($r = 0.374$).




Figura 1. Distribución del Performance Index

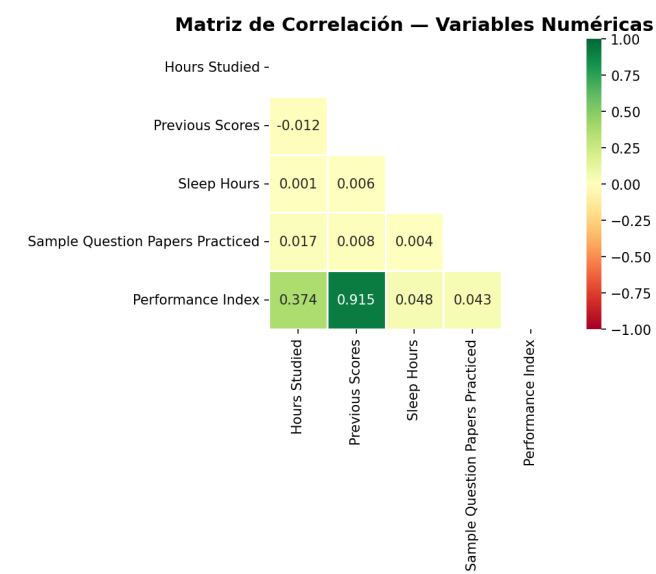


Figura 2. Matriz de correlación entre variables numéricas

2.2. Preprocesamiento y División

El flujo de preprocesamiento siguió cuatro pasos:

1. Eliminación de duplicados: remoción de registros repetidos.
2. Codificación binaria: **Extracurricular Activities:** Yes = 1, No = 0.
3. División 80/20 antes del escalado, para evitar data leakage.
4. StandardScaler ajustado exclusivamente con datos de entrenamiento y aplicado a ambos conjuntos.

La proporción 80/20 se justifica porque con ~10.000 registros el 80% garantiza variabilidad suficiente para el aprendizaje de la red; el 20% (~2.000 registros) ofrece una estimación confiable del error de generalización con baja varianza.

3. Implementación y Entrenamiento

3.1. Arquitectura MLP

Cuadro 3. Arquitectura del modelo MLP

Capa	Neuronas	Activación
Entrada	5	—
Oculto 1	64	ReLU
Dropout 1	20%	—
Oculto 2	32	ReLU
Dropout 2	20%	—
Oculto 3	16	ReLU
Salida	1	Lineal

La arquitectura decreciente (64 → 32 → 16) extrae representaciones progresivamente más abstractas. Se eligió ReLU para evitar el gradiente desvaneciente. El Dropout (20%) regulariza el modelo reduciendo el sobreajuste. La salida es una neurona sin activación (regresión de valor continuo). La función de pérdida es MSE y el optimizador base es Adam con learning rate = 0.001.

3.2. Entrenamiento del Modelo Base

El modelo fue entrenado durante 100 épocas con `batch_size=32` y validación interna del 20% del conjunto de entrenamiento. La Figura 3 muestra la evolución del MSE y MAE, con reducción sostenida del error en entrenamiento y validación, sin señales de sobreajuste.




Figura 3. Curvas de entrenamiento del modelo base (MSE y MAE)

4. Técnica de Mejora: Optimizadores

Se compararon Adam y SGD manteniendo idéntica arquitectura, datos y número de épocas. La única variable modi-

ficada fue el algoritmo de optimización, siguiendo la opción Solucionador / Optimizador de la guía de actividad.

- Adam — tasas de aprendizaje adaptativas por parámetro; convergencia rápida con menor error de validación.
- SGD (lr = 0.001, sin momentum) — gradiente acumulado del mini-batch; convergencia más lenta.

Cuadro 4. Métricas al final del entrenamiento (validación)

Optimizador	Loss val.	MAE val.
Adam	5.63	1.87
SGD	14.28	3.04

Las curvas de pérdida de ambos modelos se muestran en la Figura 4. Adam converge más rápido y alcanza menor error de validación.




Figura 4. Curvas de pérdida: Adam vs SGD

5. Evaluación del Modelo

5.1. Métricas en el Conjunto de Prueba

Cuadro 5. Métricas de regresión — Conjunto de prueba

Modelo	MSE	RMSE	MAE	R ²
Adam + Dropout	5.73	2.39	1.88	0.98
SGD + Dropout	15.16	3.89	3.15	0.96

El modelo Adam obtuvo un $R^2 = 0.98$, explicando el 98% de la variabilidad del **Performance Index**, con un MAE de apenas 1.88 puntos. SGD alcanzó $R^2 = 0.96$ con mayor error en todas las métricas.

5.2. Análisis de Overfitting

Cuadro 6. Análisis de overfitting — Modelo Adam

Conjunto	RMSE
Entrenamiento	3.80
Prueba	3.89
Diferencia	0.09

La diferencia de 0.09 puntos entre RMSE de entrenamiento y prueba indica ausencia de sobreajuste. El Dropout contribuyó a esta estabilidad.

5.3. Predicciones y Residuos

Los gráficos de la Figura 5 muestran alineación muy cercana a la diagonal de predicción perfecta. La Figura 6 confirma residuos centrados cerca de cero. La Figura 7 resume la comparación final.




Figura 5. Predicciones vs valores reales: Adam (izq.) y SGD (der.)




Figura 6. Distribución de residuos: Adam (izq.) y SGD (der.)




Figura 7. Comparación de métricas finales: Adam vs SGD

6. Respuesta a Preguntas Secundarias

Utilizando el modelo Adam, se construyeron casos hipotéticos con valores promedio variando únicamente la variable de interés.

Cuadro 7. Rendimiento esperado según horas de estudio

Horas estudio	Performance Index predicho
1	44.54
2	47.41
3	49.27
4	51.67
5	53.90
6	56.40
7	58.78
8	61.40
9	64.02

El modelo revela una relación positiva y consistente entre las horas de estudio y el rendimiento académico. Pasar de 1 a 9 horas diarias de estudio incrementa, en promedio, el Performance Index predicho en 19.48 puntos, pasando de 44.54 a 64.02. Este resultado confirma que las horas de estudio constituyen uno de los factores modificables con mayor impacto sobre el desempeño estudiantil.

Cuadro 8. Rendimiento esperado según horas de sueño

Horas de sueño	Performance Index predicho
4	53.63
5	53.87
6	54.14
7	54.42
8	54.75
9	55.36

El efecto de las horas de sueño sobre el rendimiento es moderado: pasar de 4 a 9 horas incrementa el Performance Index predicho en promedio 1.74 puntos, lo que sugiere que esta variable tiene una influencia marginal en comparación con las calificaciones previas o las horas de estudio.

Cuadro 9. Rendimiento según participación extracurricular

Participación	Performance Index predicho
No participa	54.29
Participa	55.15

La diferencia entre participar o no en actividades extracur-

riculares es en promedio 0.86 puntos, un efecto prácticamente nulo. El modelo no encuentra evidencia de que esta variable influya de manera relevante en el rendimiento académico dentro de este dataset.

7. Conclusiones

Sobre los hallazgos del modelo:

- Calificaciones previas como predictor dominante: con $r = 0.915$, es la variable más determinante del rendimiento futuro.
- Horas de estudio con efecto accionable: pasar de 1 a 9 horas incrementa el Performance Index en ~19.5 puntos.
- Sueño y exámenes de práctica con efecto marginal: apenas 1.74 puntos de diferencia entre extremos de horas de sueño.
- Actividades extracurriculares sin impacto relevante: diferencia de 0.86 puntos entre participar o no.
- Adam superó a SGD en generalización: $R^2 = 0.98$ vs 0.96 , $MAE = 1.88$ vs 3.15 en conjunto de prueba.
- Ausencia de sobreajuste: diferencia de 0.09 en RMSE entre entrenamiento y prueba; Dropout efectivo.

Sobre el proceso de modelado:

- Preprocesamiento crítico: evitar data leakage fue determinante para obtener métricas confiables.
- Arquitectura $64 \rightarrow 32 \rightarrow 16$ adecuada: balance correcto entre capacidad y complejidad para 5 variables de entrada.
- Resultado contraintuitivo en optimizadores: SGD tuvo menor loss en entrenamiento, pero Adam generalizó mejor en prueba.
- 100 épocas no óptimo: las curvas sugieren que Early Stopping habría sido suficiente.