

Predicción del Rendimiento Académico mediante una Red Neuronal Recurrente (RNN)

Calero López G.¹, Vásconez Pozo D.¹ y Viteri Ayala K.¹

¹Universidad Internacional del Ecuador

Docente: Rodriguez Chivata J.

Código fuente [Proyecto en Google Colab](#)

1. Resumen del Problema

El presente proyecto implementa una Red Neuronal Recurrente (RNN) con arquitectura GRU de dos capas para predecir el rendimiento académico de estudiantes, usando el Student Performance Dataset de Kaggle (10.000 registros). La variable objetivo **Performance Index** es numérica continua (10–100), por lo que el problema se aborda como regresión supervisada. Se elige una arquitectura recurrente porque permite representar las 5 variables como una micro-secuencia, aprovechando el estado oculto de la GRU para capturar interacciones no lineales entre ellas.

Pregunta principal: ¿Qué factores académicos y hábitos de estudio permiten predecir el rendimiento académico?

Preguntas secundarias: ¿Son las calificaciones previas el predictor dominante? ¿Influyen las horas de estudio, sueño y actividades extracurriculares?

Notebook: [Abrir en Google Colab](#)

2. Preparación del Dataset

2.1. Descripción del Dataset

El Student Performance Dataset contiene 10.000 registros de estudiantes sin valores faltantes. La distribución del **Performance Index** es aproximadamente uniforme (Figura~1). La matriz de correlación confirma que **Previous Scores** es la variable más asociada al rendimiento ($r_{\text{=0.915}}$), seguida de **Hours Studied** ($r_{\text{=0.374}}$).

Cuadro 1. Variables del modelo

Variable	Tipo	Rol
Previous Scores	Numérica	Predictora
Hours Studied	Numérica	Predictora
Sample Q. Pairs	Numérica	Predictora
Sleep Hours	Numérica	Predictora
Extracurricular Act.	Categ. (binaria)	Predictora
Performance Index	Numérica	Objetivo




Figura 1. Distribución del Performance Index




Figura 2. Matriz de correlación entre variables numéricas

2.2. Preprocesamiento y División

El flujo siguió seis pasos para evitar data leakage:

1. Eliminación de duplicados.
2. Codificación binaria: **Extracurricular Activities**
Yes = 1, No = 0.
3. División 80/20 antes del escalado.
4. StandardScaler ajustado solo con datos de entrenamiento.
5. Partición interna 80/20 para obtener train (64%) y validación (16%).
6. Reformato a pseudo-secuencia (N, 5, 1) con orden conceptual: calificaciones previas → horas de estudio → exámenes de práctica → horas de sueño → actividades extracurriculares.

3. Implementación y Entrenamiento

3.1. Selección de Arquitectura

Se compararon SimpleRNN, LSTM y GRU (1~capa, 32~unidades, mismos hiperparámetros). La GRU fue seleccionada por igualar o superar a LSTM con menos parámetros (2~compuestas vs.~3), adecuado para secuencias cortas de 5~pasos.

Cuadro 2. Comparativo de celdas recurrentes

Celda	val_loss	Params	Selecc.
SimpleRNN	mayor	menor	—
LSTM	similar	mayor	—
GRU	menor	medio	

3.2. Arquitectura GRU Final

Cuadro 3. Arquitectura del modelo GRU

Capa	Unidades	Config.
Entrada	(5, 1)	—
GRU 1	64	return_seq=True
Dropout 1	20%	—
GRU 2	32	return_seq=False
Dropout 2	20%	—
Dense oculta	16	ReLU
Salida	1	Lineal

La arquitectura decreciente (64→32→16) extrae representaciones progresivamente más abstractas. El Dropout (20%) previene el sobreajuste. La salida lineal permite predecir cualquier valor continuo.

3.3. Configuración del Entrenamiento

- Loss: MSE | Optimizador: Adam, lr = 0.001 | Batch: 64.
- EarlyStopping: patience=20, restore_best_weights=True.
- ReduceLROnPlateau: factor=0.5, patience=8, min_lr=1e-6.
- ModelCheckpoint: guarda únicamente los mejores pesos.

Las curvas de entrenamiento (Figura~2) muestran convergencia estable sin sobreajuste.




Figura 3. Curvas de pérdida (MSE) y accuracy adaptada por época

4. Evaluación del Modelo

4.1. Métricas en el Conjunto de Prueba

Cuadro 4. Métricas de regresión — Conjunto de prueba

Modelo	RMSE	MAE	R ²	MAPE
GRU (2 capas)	≈1.6	≈1.3	≈0.99	<3%

El modelo GRU alcanzó $R^2 \approx 0.99$, explicando el 99% de la variabilidad del **Performance Index**, con un MAE inferior a 1.5 puntos sobre una escala de 10–100.

4.2. Análisis de Overfitting

Las curvas de entrenamiento y validación convergen sin divergencia. **EarlyStopping** interrumpió el proceso en el punto óptimo y restauró los mejores pesos. El Dropout controló efectivamente el sobreajuste.

4.3. Predicción vs. Realidad y Residuos

Los gráficos de diagnóstico (Figuras~3 y~4) muestran alineación muy cercana a la diagonal de predicción perfecta. Los residuos están centrados en cero y son independientes (Ljung-Box $p_{>0.05}$).




Figura 4. Predicción vs. Realidad (conjunto de prueba)




Figura 5. Residuos vs. Valores Ajustados

4.4. Matriz de Confusión Adaptada

La variable continua se discretizó en tres categorías (Bajo_{≤40}, Medio~40–70, Alto_{>70}) para visualizar los errores de clasificación (Figura~5). Las confusiones ocurren únicamente entre categorías adyacentes; no se observan errores entre los extremos.




Figura 6. Matriz de confusión adaptada (Bajo / Medio / Alto)

4.5. Ejemplos de Predicciones Correctas e Incorrectas

Ejemplos de predicciones correctas (verde) e incorrectas (rojo)			
Performance Index Real	Performance Index Predicho	Error Absoluto	Resultado
28.0	28.0	0.0	✓ Bien predicho
75.0	74.98999786376953	0.009999999776482582	✓ Bien predicho
44.0	44.0099983215332	0.009999999776482582	✓ Bien predicho
66.0	65.98999786376953	0.009999999776482582	✓ Bien predicho
56.0	56.0099983215332	0.009999999776482582	✓ Bien predicho
46.0	53.720001220703125	7.7199979019165	✗ Mal predicho
77.0	70.01000213623047	6.9899977118164	✗ Mal predicho
56.0	62.81999969482422	6.820000171661377	✗ Mal predicho
50.0	43.31999969482422	6.6799982838623	✗ Mal predicho
77.0	70.38999938964844	6.61000133514404	✗ Mal predicho

Figura 7. Predicciones correctas (verde) e incorrectas (rojo)

4.6. Importancia de Variables

La importancia por permutación (caída de R^2 al barajar cada variable 10~veces) confirma que **Previous Scores** es el predictor dominante, seguido de **Hours Studied**. Las variables de hábitos (**Sleep Hours**, **Extracurricular Activities**) tienen impacto marginal dentro del modelo conjunto.




Figura 8. Importancia de variables por permutación (caída de R^2)

5. Respuesta a las Preguntas de Investigación

Usando el modelo GRU e importancia por permutación:

- ¿Calificaciones previas como predictor dominante? Sí. Mayor caída de R^2 al permutarse; $r = 0.915$ en el EDA.
- ¿Estudiar más horas mejora el desempeño? Sí, con efecto positivo moderado ($r = 0.374$).
- ¿Influyen las horas de sueño? Marginalmente; caída pequeña de R^2 al permutarlas.
- ¿Actividades extracurriculares tienen impacto? Mínimo; variable con menor importancia por permutación.

6. Conclusiones

Sobre los hallazgos del modelo:

- $R^2 \approx 0.99$: alta capacidad predictiva incluso sobre datos tabulares reformateados como pseudo-secuencias.
- Calificaciones previas como predictor dominante: mayor caída de R^2 por permutación y $r = 0.915$ en correlación.
- Sin sobreajuste: curvas de entrenamiento y validación convergen; callbacks efectivos.

- GRU superior a LSTM en este contexto: igual precisión con menos parámetros, adecuado para secuencias de 5 pasos.
- Residuos independientes: Ljung-Box $p > 0.05$.

Sobre el proceso de modelado:

- Preprocesamiento crítico: dividir antes de escalar fue determinante para métricas confiables.
- El factor decisivo fue la calidad de las variables, no la naturaleza recurrente: **Previous Scores** explica la mayor parte del R^2 .
- Callbacks estratégicos: EarlyStopping + ReduceLROnPlateau redujeron el entrenamiento sin sacrificar precisión.

Proyección Semana 3: Se explorará TabTransformer (Google, 2021) como modelo preentrenado para datos tabulares, y opcionalmente DistilBERT si el problema se reformula en texto natural. La hipótesis es que el Transfer Learning mejorará la eficiencia: alcanzar resultados equivalentes con menos datos etiquetados.