

Predicción del Rendimiento Académico mediante una arquitectura preentrenada BERT-TINY

Calero López G.¹, Vásconez Pozo D.¹ y Viteri Ayala K.¹

¹Universidad Internacional del Ecuador
Docente: Rodríguez Chivata J.

Código fuente [Proyecto en Google Colab](#)

1. Resumen del Problema

El presente proyecto implementa una arquitectura pre-entrenada (BERT-Tiny, 4.39M parámetros) con Transfer Learning y Fine-Tuning para predecir el rendimiento académico de estudiantes a partir de variables relacionadas con hábitos de estudio, antecedentes académicos y actividades complementarias. La variable objetivo **Performance Index** es numérica continua (10–100), por lo que el problema se aborda como regresión supervisada. Se complementa con TabPFN como referencia fundacional, y se incorporan LIME y SHAP para validar las decisiones del modelo. Este informe cierra el ciclo de tres semanas respondiendo las preguntas de investigación del proyecto con evidencia acumulada de MLP, GRU y BERT-Tiny.

Pregunta principal: ¿Qué factores académicos y hábitos de estudio permiten explicar o predecir el rendimiento académico de un estudiante?

Preguntas secundarias: (1)~¿Las calificaciones previas son el principal predictor? (2)~¿Estudiar más horas se asocia con mejor desempeño? (3)~¿Las horas de sueño influyen en el rendimiento? (4)~¿Las actividades extracurriculares tienen impacto? (5)~¿La práctica de exámenes contribuye a mejorar los resultados?

2. Selección y Justificación del Modelo

2.1. Comparativa de Arquitecturas

Se evaluaron cuatro arquitecturas candidatas antes de seleccionar la estrategia final (Tabla~1).

Cuadro 1. Arquitecturas pre-entrenadas evaluadas

Modelo	Enfoque	Selec.
TabNet	Atención dispersa secuencial	No
TabPFN	In-Context Learning (sin entrenar)	Sí (ref.)
TabTransformer	Atención sobre categorías	No
BERT-Tiny	Transformer texto (4.39M par.)	Sí (impl.)

Se seleccionaron TabPFN (cero épocas, milisegundos en CPU) y BERT-Tiny (Transfer Learning real desde lenguaje pre-entrenado). Las 5 variables se serializan como texto estructurado ("**hours studied: 7 previous scores: 99...**") para que el tokenizador procese cada registro como secuencia.

3. Adaptación del Dataset

El pipeline añade pasos específicos respecto a Semanas 1–2:

1. Limpieza base: 127 duplicados eliminados; división 80/20 antes del escalado (sin data leakage).
2. Serialización a texto: cada fila tabular se convierte en cadena clave:valor compatible con BERT.
3. Tokenización: `BertTokenizer` (30.522 tokens) + padding fijo a 32 tokens.
4. Normalización del target: **Performance Index** escalado a $[0, 1]$ para estabilizar el entrenamiento.
5. Pipeline eficiente: `tf.data.Dataset` con `tf.py_function` para tokenización en tiempo real.

4. Estrategia de Transfer Learning y Fine-Tuning

4.1. Modificación de Arquitectura

Se eliminó la cabeza de clasificación original de BERT-Tiny y se añadió una cabeza de regresión sobre el token [CLS] de salida (Figura~1).

```
Texto serializado
|
BertTokenizer (HuggingFace)
|
BERT-Tiny Backbone (4.39M)
  Embedding      [FROZEN Fases 1-2]
  Transformer L0  [FROZEN Fases 1-2]
  Transformer L1  [FROZEN F1/ACTIVO F2]
  |
[CLS] -> (batch, 128)
  |
BatchNorm->Dense(64,relu)->Dropout(0.3)
->Dense(32,relu)->Dropout->Dense(1,lin)
```

Figura 1. Arquitectura BERT-Tiny con cabeza de regresión

4.2. Estrategia de Congelamiento en Dos Fases

Cuadro 2. Configuración de entrenamiento por fase

Fase	Capas activas	Params	LR
Fase 1	Solo cabeza	~10K	3e-3
Fase 2	+ Transf. L1	~3.5M	2e-5

Criterio de congelamiento: en Fase~1, el backbone permanece congelado porque la cabeza (pesos aleatorios) generaría gradientes destructivos sobre las representaciones pre-entrenadas — fenómeno de Catastrophic Forgetting. Al estabilizarse Fase~1, se descongela únicamente la última capa Transformer con $lr = 2 \times 10^{-5}$, preservando el conocimiento lingüístico en las capas más profundas.

5. Entrenamiento y Análisis de Sobreajuste

5.1. Configuración

- Optimizador: AdamW (weight decay = 0.01).
- Pérdida: MSE en ambas fases.
- Callbacks: `EarlyStopping` (patience=5, `restore_best_weights`), `ReduceLROnPlateau` (factor=0.5, patience=3), `ModelCheckpoint`.

5.2. Overfitting observado y estrategia de control

Las curvas de entrenamiento (Figura~2) revelan un gap tren-validación de $\approx 20\%$ en MSE al finalizar Fase~2. Este gap es estructural: BERT-Tiny (4.39M parámetros activos en Fase~2) tiene capacidad muy superior a la complejidad del problema (5 variables, $\$<\$10K$ muestras). La serialización textual agrava esto al generar tokens redundantes ("hours" y "studied" como tokens distintos) que el Transformer memoriza en lugar de generalizar.

Las medidas de control fueron `EarlyStopping` (restauró los mejores pesos de validación) y Dropout (0.3 y 0.2 en la cabeza). El resultado en test muestra $R^2=0.9047$, confirmando generalización aceptable pese al gap.




Figura 2. Dashboard de entrenamiento: curvas MSE Fase 1 y Fase 2, diagnóstico de predicciones y residuos

6. Evaluación del Modelo

6.1. Métricas en conjunto de prueba

Cuadro 3. Métricas BERT-Tiny — Conjunto de prueba

Modelo	MAE	RMSE	R ²
BERT-Tiny (TL)	4.81	5.80	0.9047

6.2. Diagnóstico de predicciones y residuos




Figura 3. Real vs. Predicho e histograma de residuos (BERT-Tiny, conjunto de prueba)

El gráfico Real vs. Predicho muestra alineación razonable con la diagonal ideal, con dispersión mayor en valores extremos — patrón típico del sobreajuste parcial documentado. Los residuos siguen una distribución aproximadamente centrada en cero.

7. Interpretabilidad (XAI)

7.1. LIME — Análisis local




Figura 4. LIME: importancia de tokens para bajo, medio y alto rendimiento

`LimeTextExplainer` perturbó el texto serializado para tres instancias representativas. **previous scores** y **hours studied** dominan con pesos positivos en alto rendimiento y negativos en bajo rendimiento en todos los casos. **Extracurricular** muestra importancia pequeña y variable, señal de contexto más que de predictor.

7.2. SHAP — Importancia global y comparativa LIME vs. SHAP




Figura 5. SHAP Beeswarm: importancia global (100 instancias, KernelExplainer con background k -means, $k = 50$)

El ranking SHAP confirma: **Previous Scores** > **Hours Studied** > **Practice Papers** > **Sleep Hours** > **Extracurricular**. La Figura~6 compara importancia normalizada entre ambas técnicas.




Figura 6. Comparativa LIME vs. SHAP: importancia normalizada por variable. Alta concordancia en los dos predictores dominantes.

La concordancia entre LIME y SHAP en el ranking de las dos variables principales valida la robustez de las explicaciones: ambas técnicas, con metodologías distintas (aproximación lineal local vs. valores de Shapley de teoría de juegos), llegan a la misma conclusión sobre qué variables impulsan el modelo.

8. Comparativa Completa entre Semanas

Cuadro 4. Comparativa de todos los modelos — Semanas 1 a 3

S.	Modelo	MAE	RMSE	R ²	Acc.*
1	MLP (Adam)	1.88	2.39	0.9800	94.58%
1	MLP (SGD)	3.15	4.03	0.9564	94.58%
2	RNN — GRU	1.51	2.09	0.9882	94.58%
3	TabPFN	1.80	2.30	0.9800	~90% [†]
3	BERT-Tiny (TL)	4.81	5.80	0.9047	~90%

9. Respuesta a Preguntas de Investigación

Pregunta principal — ¿Qué factores académicos y hábitos de estudio permiten predecir el rendimiento académico?

Los cuatro modelos evaluados en las tres semanas (MLP, GRU, TabPFN, BERT-Tiny) coinciden: el **Performance Index** puede predecirse con alta precisión (R² entre 0.90 y 0.9882) a partir de las 5 variables. Las técnicas XAI (LIME, SHAP) e importancia por permutación identifican dos factores dominantes: **Previous Scores** (r=0.915) y **Hours Studied** (r=0.374). Las variables de hábitos (sueño, exámenes de práctica, actividades extracurriculares) tienen impacto marginal dentro del modelo conjunto.

P.S.1 — ¿Las calificaciones previas son el principal predictor?

Sí, de forma consistente en las tres semanas. **Previous Scores** registra la mayor correlación con el target (r=0.915), la mayor caída de R² al permutarse en la GRU (Semana~2) y el mayor valor SHAP absoluto medio sobre BERT-Tiny (Semana~3). El hallazgo es robusto a través de cuatro arquitecturas y dos técnicas de explicabilidad.

P.S.2 — ¿Estudiar más horas se asocia con mejor desempeño?

Sí, con efecto positivo y accionable. El MLP (Semana~1) cuantificó que pasar de 1 a 9 horas diarias de estudio eleva el Performance Index predicho en \$19.5 puntos (de 44.54 a 64.02), manteniendo las demás variables en su valor promedio. LIME y SHAP (Semana~3) confirman que **Hours Studied** es el segundo predictor en importancia en todos los niveles de rendimiento.

P.S.3 — ¿Las horas de sueño influyen en el rendimiento?

Marginalmente. El MLP (Semana~1) estimó una diferencia

de solo 1.74 puntos entre los extremos de horas de sueño (4 vs.~9 horas). La importancia por permutación (GRU, Semana~2) y SHAP (BERT-Tiny, Semana~3) ubican **Sleep Hours** en tercer o cuarto lugar, con impacto muy inferior al de calificaciones previas y horas de estudio.

P.S.4 — ¿Las actividades extracurriculares tienen impacto sobre el desempeño?

Mínimo, prácticamente nulo. El MLP (Semana~1) estimó una diferencia de apenas 0.86 puntos entre participar o no en actividades extracurriculares. LIME muestra pesos pequeños y variables en los tres niveles de rendimiento; SHAP la ubica en último lugar en importancia global. Actúa como señal de contexto, no como predictor con poder explicativo propio.

P.S.5 — ¿La práctica de exámenes contribuye a mejorar resultados?

Levemente. **Sample Question Papers Practiced** aparece en tercer lugar en el ranking SHAP de BERT-Tiny (Semana~3), por encima de sueño y actividades extracurriculares, pero muy por debajo de calificaciones previas y horas de estudio. La correlación directa con el target (r=0.048) confirma un efecto positivo pequeño pero consistente entre modelos.

10. Conclusiones

- La GRU es el mejor modelo del proyecto (MAE = 1.51, R² = 0.9882, Accuracy = 94.58%), seguida de TabPFN y MLP-Adam (R² ≈ 0.98). La arquitectura especializada supera al conocimiento pre-entrenado genérico cuando el dominio de pre-entrenamiento es ajeno al problema.
- **Previous Scores** es el predictor dominante (r = 0.915), confirmado por permutación (GRU), LIME y SHAP (BERT-Tiny) en las tres semanas. **Hours Studied** ocupa el segundo lugar con efecto accionable pedagógicamente. El resto de variables (**Sleep Hours**, **Practice Papers**, **Extracurricular**) tienen impacto marginal y consistente en todos los modelos.
- Proyección: la GRU se consolida como arquitectura de producción; SHAP y LIME como capa de explicabilidad ética para docentes y directivos.